

Briefing — Call mit Marja Wahl (RAUSCH), Di 26.05.2026

Projekt: KI-gestützte Anomalieerkennung im Energieverbrauch (DatenWerKIOS, Cluster 2 / Aufgabe 3).
Bearbeitende: Jakob & Felix · THWS, M. Digital Business Systems. Zweck dieses Dokuments: kompakter
Stand für den Call. Methodische Tiefe in docs/konzept/methodenwahl_defense.md und
docs/konzept/konzept.md.

1. Executive Summary

Wir entwickeln eine erklärbare Pipeline zur Anomalieerkennung auf Smart-Meter-Lastgängen.
Forschungsfrage: Wie lässt sich eine erklärbare Anomalieerkennung bauen, die (a) ohne
pro-Standort-Training auf neue Liegenschaften übertragbar ist und (b) automatisierte
Handlungsempfehlungen generiert?

Stand: EDA, Feature-Engineering und eine Z-Score-Baseline sind fertig und reproduzierbar (Notebooks
01–03). Die ARIMA-Hauptmethode ist der nächste Schritt.

Wichtigster Befund bisher: Die Baseline flaggt fast ausschließlich Feiertage/Schließtage als „Anomalien“ —
ein erklärbarer Fehler der reinen Saisonzerlegung. Das motiviert direkt die gewählte Hauptmethode
(SARIMAX mit Feiertags-Regressor). Wir bringen also nicht nur Zahlen, sondern eine datenbegründete
Methodenwahl mit.

Für den Call brauchen wir von dir v. a.: Standorte der Baumärkte, etwaige Anomalie-Labels, Einordnung
Lastgang-vs-ZRV-Daten und Beispiele typischer Anomalien aus eurer Praxis (Details §6).

2. Datenbasis & EDA-Befunde

- Umfang: 77 Excel-Dateien in 5 Branchen (Baumärkte, Ladestationen, Tankstellen, Handel, Büro),
15-Minuten-Auflösung, Zeitraum ~2023-01-01 bis 2026-03-13.
- Hauptscope: Baumärkte (26 Zähler). Nach Ausschluss von 3 flachen Zählern (Baumarkt_01/_02/_04, $v_{max} < 1$ kW — vermutlich Einheiten-Bug W statt kW oder Unterzähler) verbleiben 23 solide Zähler. Validierung:
Handel/Lastgang_34 (kWh + Status-Flag).
- Drei Quellformate vereinheitlicht (Lastgang kWh, ZRV kW, ZRV mit Metadaten-Kopf) → einheitliches
Schema (kW, MultiIndex meter_id × timestamp, Europe/Berlin); Loader mit stabiler meter_id-Zuordnung.
- Saisonalität: dominant täglich + wöchentlich (ACF-Peaks bei lag 24/168); k = 3 Tagesprofil-Cluster (über
Silhouette bestimmt).
- Externe Daten integriert: DWD-Wetter (Würzburg als Proxy bis Standortklärung) und
EPEX-Day-Ahead-Preise (DE-LU), beide gecacht und auf Stundenebene gejoint.
- Wetter ↔ Verbrauch (auflösungsabhängig — methodisch zentral):

Auflösung	Korrelation Temp↔Verbrauch	Lesart
stündlich, roh	$r \approx 0,11$	Tageszyklus überdeckt das Signal (Artefakt)
Tagesmittel	median $r \approx -0,32$ (22/23 negativ)	klares Heizsignal
STL-Residuum	median $r \approx 0,02$	Wetter durch STL bereits absorbiert

→ Konsequenz: der Anomalie-Score (STL-Residuum) ist wetterrobust.

3. Methodische Architektur (mit Kurzbegründung)

Datenfluss: Smart-Meter → Loader (Normalisierung, tz, stabile IDs) → Feature-Engineering (+
Wetter/Preis/Kalender) → Detection → Score → LLM-Empfehlung → Dashboard.

Baustein	Wahl	Kurzbegründung (Details: methodenwahl_defense.md)
Saisonbereinigung	STL (period=168, robust)	Trend + robuste Saison, zitierbar; Residuum empirisch wetterunabhängig (#3)
Baseline	globaler Z-Score STL-Residuum	auf einfacher, voll erklärbarer Vergleichsmaßstab (#7, #8)
Cluster	k-Means auf Tagesprofilen, k=3	normierten interpretierbare Centroide für Modell-Zuordnung (#4, #5)

Baustein	Wahl		Kurzbeurteilung (Details: methodenwahl_defense.md)		
Hauptmethode	SARIMAX Residuum/Prädiktionsintervall Score	pro Cluster, als	modelliert Konfidenzband	Zeitstruktur ist erklärbar	explizit, (#9)
Kalender	is_holiday-Exogen in SARIMAX		direkt motiviert	durch (#10)	Baseline-Befund
Empfehlungen	lokales LLM (Llama 3.2 3B) via Ollama, JSON-Schema		DSGVO-konform erzwungen, 3B genügt	lokal; (#13, #14)	Format
Übertragbarkeit	cluster-basiert (Centroid-Zuordnung, pro-Zähler-Training)	kein	adressiert (#15)	Forschungsfrage	(a)

Bewusst nur diskutiert, nicht implementiert: LSTM und Foundation Models (Chronos/TranAD/TimeRCD) — Begründung: Erklärbarkeit als nicht-funktionales Pflichtmerkmal in kritischer Energieinfrastruktur (#11, #12).

Warum SARIMAX statt Isolation Forest (Kernargument): Isolation Forest ignoriert die zeitliche Struktur (statische Dichteschätzung), SARIMAX modelliert die Erwartung für jeden Zeitpunkt → das Residuum ist die echte Kontext-Anomalie, und das Konfidenzband ist im Dashboard unmittelbar nachvollziehbar.

4. Baseline-Ergebnisse (Z-Score auf STL-Residuum)

- 14.712 Anomalien bei $|z| > 3$ über 23 Zähler; Rate 1,7–3,2 % pro Zähler (sehr gleichmäßig → systematischer Methoden-Effekt, kein einzelner Defekt-Zähler).
- 2,84 % beobachtet vs. 0,27 % theoretisch → fat-tailed Residuen; die Schwelle ist empirisch zu kalibrieren.
- Alle Top-10-Anomalien sind Feiertage (negative Residuen / Schließstage: Weihnachten, Ostermontag, Tag der Deutschen Einheit, Heilige Drei Könige) — keine Defekte, sondern Schließungen.
- Wochenenden werden problemlos absorbiert (STL lernt die Wochenstruktur) — Fehlalarme entstehen nur an irregulären Feiertagen.

Vier Limitationen (motivieren die Hauptmethode): L1 fat tails → Schwelle empirisch; L2 keine Feiertags-Awareness → SARIMAX mit is_holiday; L3 Heteroskedastizität → kontextabhängiges Prädiktionsintervall; L4 kein zeitlicher Kontext → forecasting-basierte Bewertung.

5. Nächste Schritte

- SARIMAX mit is_holiday pro Cluster (Woche 3) — Zielnachweis: Verschwinden der Feiertags-Fehlalarme bei besserem Treffer auf echte Events.
- Übertragbarkeitstest auf einer ungesehenen Branche (ergebnisoffen).
- LLM-Empfehlungskomponente (Ollama, strukturierter Output).
- Dashboard-Wireframe + Paper/Poster.

6. Offene Punkte für Marja (Call-Ziel)

1. Standorte der Baumärkte — für korrekte Wetterstationen und das richtige Feiertags-Bundesland (unsere Top-10 enthalten „Heilige Drei Könige“ → deutet auf Süddeutschland/Bayern; bitte bestätigen).
2. Labels für bekannte Anomalien — gibt es dokumentierte Störfälle/Events? Schon wenige würden eine echte Evaluation (statt „ground-truth-lite“) ermöglichen.
3. Vergleichbarkeit Lastgang (kWh + Status-Flag) vs. ZRV (kW) — sind das dieselben Messpunkte in anderem Export? Und: sind die flachen Zähler ($v_{max} < 1$ kW) ein Einheiten-Thema (W statt kW) oder Unterzähler?
4. Typische Anomalien aus eurer Praxis — welche Muster seht ihr real (Dauerlast nachts, Lastabwürfe, defekte Kälte-/Lüftungstechnik, Stand-by-Verbräuche)? Das schärft, worauf die Methode optimieren soll.