

Methodenwahl-Verteidigung — DatenWerKIOS

Anomalieerkennung

Interne Verteidigungsgrundlage für jede methodische Entscheidung im Projekt. Adressatin: u. a. Marja Wahl (Data Scientist, RAUSCH) und Prof. Müßig — fachlich versiert, daher technisch präzise statt oberflächlich.

Format je Entscheidung: Entscheidung · Begründung · Verworfen Alternativen · Ehrliche Gegenargumente & Replik · Antizipierte Verteidigungsfragen · Literatur.

Querverweise: docs/konzept/konzept.md, docs/konzept/datenprofil.md, Notebooks 01_eda / 02_features / 03_baseline_zscore, Skills smart-meter-eda / anomalie-methodenwahl / external-data-apis.

Literaturhinweis: Alle bibliografischen Angaben sind vor der finalen Abgabe gegen die Originale zu verifizieren (Jahr, Seiten, DOI). Es wurden keine Quellen erfunden; wo eine Referenz unsicher ist, ist das markiert.

Inhaltsverzeichnis

- A. Scope & Daten — Entscheidungen 1, 2, 16, 17, 18
 - B. Saisonzerlegung & Clustering — 3, 4, 5, 6
 - C. Anomalieerkennungs-Methoden — 7, 8, 9, 10, 11, 12
 - D. Handlungsempfehlungen (LLM) — 13, 14
 - E. Übertragbarkeit — 15
 - Literaturverzeichnis
-

A. Scope & Daten

1. Hauptdatensatz Baumärkte, Validierung Handel/Lastgang_34

Entscheidung. Wir entwickeln und trainieren die Pipeline auf den 26 Baumarkt-Zählern (ZRV-Format, kW) und nutzen Handel/Lastgang_34 (kWh + Status-Flag) als unabhängigen Validierungsfall.

Begründung. - Größte homogene Kohorte: Baumärkte sind mit 26 Zählern die größte Gruppe gleichartiger Liegenschaften → erlaubt Clusterbildung und Querschnittsvergleiche, die bei Einzelzählern unmöglich wären. - Klare, gut interpretierbare Saisonstruktur: ausgeprägte Öffnungszeiten-Profile (Tages-/Wochenzyklus, ACF-Peaks bei lag 24/168, siehe 01_eda) sind ideal, um Saisonzerlegung und Forecasting methodisch sauber zu demonstrieren. - Lastgang_34 als methodischer Gegentest: anderes Quellformat (kWh statt kW), anderer Zeitraum, mit Qualitäts-Flag (Ersatzwert). Damit prüfen wir, ob die Pipeline format- und einheitenrobust ist, statt sie nur auf einer homogenen Quelle zu zeigen. - Reproduzierbarkeit: ein fester Hauptscope verhindert „cherry-picking“ über alle Branchen hinweg.

Verworfen Alternativen. - Alle 5 Branchen gleichzeitig: zu heterogen (Ladestationen-Lastspitzen bis 1.218 kW vs. Büro mit einem Zähler) — vermischt Methodenentwicklung mit Generalisierung und verwässert die Argumentation. - Nur ein einzelner Zähler: keine Cluster-/Übertragbarkeitsaussage möglich.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Baumärkte sind ein Sonderfall (planbare Öffnungszeiten); die Methode könnte auf unregelmäßigeren Lasten (Ladestationen) scheitern.“ — Replik: Korrekt, und genau deshalb ist die Übertragbarkeit (Entscheidung 15) ein eigener, ergebnisoffener Testteil; wir behaupten nicht, dass die auf Baumärkten trainierte Pipeline ungetestet auf andere Branchen läuft. - Gegenargument: „Nur ein Validierungszähler ist dünn.“ — Replik: Stimmt; Lastgang_34 ist ein Format-/Einheiten-Test, kein statistischer Generalisierungsbeleg. Letzterer ist der branchenübergreifende Übertragbarkeitstest.

Antizipierte Verteidigungsfragen. - „Warum nicht die datenreichste Branche (Ladestationen, 26 Zähler) als Hauptscope?“ → Ladestationen haben hochvolatile, ereignisgetriebene Lastprofile mit extremer Magnituden-Spreizung; die Saison-/Forecasting-Methodik lässt sich dort weniger sauber isoliert demonstrieren. Sie sind aber ein guter Kandidat für den Übertragbarkeitstest.

Literatur. —

2. Ausschluss der flachen Zähler (Baumarkt_01, _02, _04)

Entscheidung. Drei Zähler mit Maximalleistung < 1 kW werden aus der Hauptanalyse ausgeschlossen (nicht gelöscht), siehe 01_eda Block 2b und 02_features Block 1.

Begründung. - Physikalisch unplausibel: ein Baumarkt mit Spitzenlast < 1 kW ist betrieblich nicht plausibel (übrige Zähler: bis ~165 kW). - Datengenerierende Ursache unklar: wahrscheinlichste Hypothese ist ein Einheiten-Bug (Faktor 1000, W statt kW), da × 1000 die Maxima in den plausiblen Bereich der übrigen Zähler

hebt; alternativ Teilstrang-/Unterzähler oder Defekt. - Verzerrungsvermeidung: normalisierte Tagesprofile dieser Zähler sind faktisch Rauschen (Division durch ~ 0 -Varianz) → würden Clustering und Score-Verteilungen verzerren. - Transparenz: Ausschluss ist dokumentiert und reversibel; die konkreten meter_id sind festgehalten.

Verworfenen Alternativen. - Behalten und mitskalieren: ohne Klärung der Ursache spekulativ; ein falsch angenommener Faktor 1000 würde künstliche Werte erzeugen. - Stilles Löschen: verletzt Reproduzierbarkeit und DSGVO-Sorgfalt.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Ihr werft echte Daten weg — vielleicht sind das valide Unterzähler.“ — Replik: Deshalb ausschließen, nicht löschen, und explizit als offener Punkt für Marja geführt (Standort/Einheit klären). Sobald die Ursache feststeht, können sie korrekt skaliert wieder aufgenommen werden.

Antizipierte Verteidigungsfragen. - „Schwelle 1 kW — willkürlich?“ → Sie trennt eine klar separierte Gruppe ($v_{\max} \approx 0,1$ kW) von der nächsten Größenordnung (≥ 5 kW); es gibt keine Zähler im Bereich 1–5 kW, die Wahl ist also robust gegen die genaue Schwelle.

Literatur. —

16. Würzburg als Wetter-Proxy

Entscheidung. Bis zur Klärung der echten Standorte (Marja-Call) nutzen wir Würzburg (DWD/Brightsky, DEFAULT_LAT/LON = 49.7913, 9.9534) als Wetter-Proxy.

Begründung. - Räumliche Korrelation des Wetters: Temperatur und Großwetterlagen sind in Deutschland über mehrere hundert Kilometer stark korreliert; der Proxy verzerrt Absolutwerte minimal, die zeitliche Struktur (Tag/Nacht, Warm-/Kaltphasen) jedoch kaum. - Empirisch entschärft: Wie 02_features zeigt, ist das STL-Residuum ohnehin nahezu wetterunabhängig (median $r \approx 0,02$). Der für die Anomalieerkennung genutzte Score hängt also kaum an der exakten Wetterstation. - Pragmatisch & reproduzierbar: ein definierter Proxy ist besser als gar kein Wetter; Standort ist eine .env-Konstante, später ohne Code-Änderung austauschbar.

Verworfenen Alternativen. - Auf Wetter ganz verzichten: verschenkt ein erklärendes Feature und die Plausibilisierung (Kältetag vs. Defekt). - Mit Wetter warten bis Standorte bekannt: blockiert die Pipeline-Entwicklung unnötig.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Falscher Standort = falsche Heizgradtage.“ — Replik: Auf Tagesaggregat-Ebene zeigt sich zwar ein reales Heizsignal (median $r \approx -0,32$), aber dieses landet via STL in Trend/Saison, nicht im Anomalie-Score. Der Proxy-Fehler propagiert also nicht in die Detektion; für eine spätere absolute Effizienzbewertung wären echte Standorte nötig — das ist ein offener Punkt.

Antizipierte Verteidigungsfragen. - „Wie groß ist der Proxy-Fehler quantitativ?“ → Nicht final quantifiziert (Standorte unbekannt); die Sensitivität ist durch die ≈ 0 -Residuum-Korrelation aber nach oben begrenzt.

Literatur. —

17. Zielzeitzone Europe/Berlin mit expliziter DST-Regel

Entscheidung. Alle Reihen werden auf Europe/Berlin (tz-aware) gebracht; die DST-Mehrdeutigkeit wird explizit geregelt statt über ambiguous='infer'.

Begründung. - Korrektheit an DST-Wenden: tz_localize(..., ambiguous='infer') von pandas funktioniert nur über genau einen Übergang und scheitert an mehrjährigen Reihen mit Lücken (Fehler „N dst switches“); es lief faktisch immer in den lossy Fallback ambiguous=False. - Definierte Konvention: Herbst-Rückstellung — erste (frühere) Belegung = Sommerzeit, zweite = Winterzeit; Frühjahrslücke — nonexistent='shift_forward'. Dokumentiert im Loader-Docstring und datenprofil.md. - Reproduzierbar & verlustfrei: kein stilles Zusammenfallen doppelter Stunden (verifiziert: 0 doppelte Index-Paare über alle Zähler).

Verworfenen Alternativen. - Naive Zeitstempel belassen: DST-Brüche erzeugen Geister-/NaT-Zeilen beim Join mit UTC-Wetter/Preisen. - Alles in UTC rechnen: erschwert die fachliche Interpretation (Öffnungszeiten sind Wanduhrzeit).

Ehrliche Gegenargumente & Replik. - Gegenargument: „ambiguous='infer' ist Standard — warum abweichen?“ — Replik: Es ist Standard für Einzelübergänge. Bei 3 Jahren mit Lücken ist es nachweislich unbrauchbar; unsere explizite Regel ist genau das, was infer zu tun versucht, nur robust.

Antizipierte Verteidigungsfragen. - „Wie viele Datenpunkte betrifft das überhaupt?“ → Pro Jahr eine doppelte/fehlende Stunde je Zähler — quantitativ klein, aber ein unbehandelter Bruch kann den ganzen Reindex/Join verschieben, daher die Sorgfalt.

Literatur. —

18. Zieleinheit kW (statt kWh)

Entscheidung. Einheitliche Zielgröße ist Leistung in kW; kWh-Lastgänge werden über das Messintervall umgerechnet ($kW = kWh / \text{Intervall}_h$, bei 15 min / 0,25).

Begründung. - Mehrheitliche Quelllage: die große Mehrzahl der Dateien (ZRV) liegt bereits in kW vor; eine Umrechnung der wenigen kWh-Lastgänge ist der kleinere Eingriff. - Auflösungsunabhängigkeit: Leistung (kW) ist eine Momentangröße, unabhängig vom Aggregationsintervall — robust gegen die später nötige Resampling-Schritte (z. B. EPEX-Granularitätswechsel). - Direkte Interpretierbarkeit: Lastgänge, Tagesprofile und ARIMA-Konfidenzbänder sind in kW intuitiv lesbar; der Loader normalisiert intervallabhängig (src/eda/loader.py).

Verworfenen Alternativen. - kWh als Ziel: Energie ist intervallabhängig; beim Mischen von 15-min- und (späteren) Stundenaggregaten fehleranfällig.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Für Effizienz-/Kostenaussagen ist kWh die natürliche Einheit.“ — Replik: Stimmt; kWh ist jederzeit als $kW \times \text{Intervall}$ rekonstruierbar. Für die Detektion ist kW robuster, für die Berichterstattung (z. B. „Mehrverbrauch in kWh“ im Dashboard) rechnen wir zurück.

Antizipierte Verteidigungsfragen. - „Verfälscht die Umrechnung etwas?“ → Nein, sie ist eine lineare, exakte Transformation bei bekanntem Intervall.

Literatur. —

B. Saisonzerlegung & Clustering

3. STL statt (dow, hour)-Mittel zur Saisonbereinigung

Entscheidung. Saison/Trend werden per STL (Seasonal-Trend decomposition using Loess, period=168, robust) entfernt, nicht über ein einfaches (Wochentag, Stunde)-Mittel.

Begründung. - Explizite Trendkomponente: über 3 Jahre ist ein Trend (z. B. Geschäftsentwicklung, Effizienzmaßnahmen) real; ein (dow, hour)-Mittel ignoriert ihn und schiebt ihn ins Residuum. - Robustheit: der robuste Loess-Smoother dämpft den Einfluss von Ausreißern auf die Saisonschätzung — wichtig, weil wir Ausreißer ja gerade suchen und nicht in die Baseline einbacken wollen. - Zitierbare Standardmethode (Cleveland et al. 1990) statt einer ad-hoc-Heuristik. - Empirisch validiert: das STL-Residuum korreliert praktisch nicht mehr mit der Temperatur (median $r \approx 0,02$, 02_features) → Saison + Wetter sind sauber absorbiert, das Residuum ist die „echte“ Untypisiertheit.

Verworfenen Alternativen. - (dow, hour)-Mittel: einfach, aber ohne Trend, nicht robust, ohne Referenz. - Klassische additive/multiplikative Zerlegung (seasonal_decompose): gleitender Mittelwert ist weniger ausreißerrobust und unflexibler als Loess.

Ehrliche Gegenargumente & Replik. - Gegenargument: „STL mit period=168 modelliert nur die Wochensaison; die Tagesform steckt mit drin, aber eine echte multi-saisonale Zerlegung (Tag und Woche) wäre sauberer (z. B. MSTL).“ — Replik: Berechtigt. Der 168er-Zyklus enthält die 7 Tagesprofile, fängt die dominante Struktur also ab; MSTL ist ein sinnvoller Ausbau und in der Diskussion als Erweiterung genannt. - Gegenargument: „STL kennt keine Feiertage.“ — Replik: Exakt der in 03_baseline belegte Befund; daraus folgt nicht „STL verwerfen“, sondern „Feiertage als exogene Information in die Hauptmethode (SARIMAX, Entscheidung 10)“.

Antizipierte Verteidigungsfragen. - „Warum period=168 und nicht 24?“ → 24 würde nur die Tagessaison entfernen und die Werktag/Wochenende-Differenz im Residuum lassen; 168 erfasst beides.

Literatur. Cleveland et al. (1990); Hyndman & Athanasopoulos (2021, Kap. zu STL/MSTL).

4. k-Means statt DBSCAN für die Zähler-Cluster

Entscheidung. Zähler werden anhand normierter mittlerer Tagesprofile mit k-Means geclustert (siehe 01_edu Block 5).

Begründung. - Form, nicht Dichte: wir suchen prototypische Tagesprofile (Centroide), die später für die Cluster-Zuordnung neuer Zähler dienen — k-Means liefert genau interpretierbare Centroide. - Kleine, vollbesetzte Menge: 23 Zähler ohne ausgeprägte „Noise“-Punkte (flache Zähler sind bereits ausgeschlossen) — der DBSCAN-Vorteil (Rauschpunkte als „kein Cluster“) greift hier kaum. - Definierte Clusterzahl nötig: für „ein ARIMA-Modell pro Cluster“ brauchen wir eine feste, kleine Anzahl Cluster — k-Means liefert das direkt.

Verworfenen Alternativen. - DBSCAN: keine festen Centroide, Clusterzahl datenabhängig, sehr sensitiv gegenüber eps/minPts in standardisierten 96-dim-Profilen; eignet sich eher zum Finden untypischer Tage als zum Gruppieren Zähler. - Hierarchisches Clustering: gute Alternative (Dendrogramm), aber ohne native Centroide für die Zuordnung; als Robustheitscheck denkbar.

Ehrliche Gegenargumente & Replik. - Gegenargument: „k-Means nimmt sphärische, gleich große Cluster an

(euklidisch) — bei Lastprofilen fragwürdig." — Replik: Zutreffend; wir mildern das durch Normierung pro Profil (Form statt Magnitude) und prüfen die Clustergüte via Silhouette. Eine korrelationsbasierte Distanz wäre ein sinnvoller Robustheitscheck (Diskussion). - Gegenargument: „k-Means ist nicht deterministisch (Init).“ — Replik: fester random_state, n_init=10.

Antizipierte Verteidigungsfragen. - „Warum nicht direkt auf den Rohprofilen clustern?“ → Dann dominiert die Magnitude (große Zähler), nicht die Form; daher Normierung — und die Magnitude wird separat betrachtet (Entscheidung 6).

Literatur. Lloyd (1982); MacQueen (1967); Ester et al. (1996, DBSCAN, als Kontrast).

5. k = 3 (begründet über Elbow + Silhouette)

Entscheidung. Die Clusterzahl wird nicht fix gesetzt, sondern über Elbow (Inertia) und Silhouette über k = 2...8 gewählt; das Maximum der Silhouette liegt bei k = 3 (01_eda Block 5).

Begründung. - Datengetrieben statt angenommen: explizite Modellselektion statt eines Bauchwerts. - Silhouette als Trennschärfemaß (Rousseeuw 1987) bewertet Kohäsion vs. Separation; k=3 maximiert sie. - Sparsamkeit: wenige, klar unterscheidbare Tagesprofil-Typen sind interpretierbar und tragen die „ein ARIMA-Modell pro Cluster“-Logik.

Verworfenen Alternativen. - Fixes k=4 o. ä.: explizit vermieden (kein Beleg). - Großes k: überanpassend, kleine Cluster mit zu wenig Zählern für stabile ARIMA-Modelle.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Elbow ist subjektiv, Silhouette bei nur 23 Punkten instabil.“ — Replik: Stimmt, deshalb beide Kriterien gemeinsam und der Plot offengelegt; k=3 ist zudem fachlich plausibel (z. B. unterschiedliche Öffnungs-/Lüftungsregime). Eine Bootstrap-Stabilitätsanalyse wäre ein sinnvoller Zusatz. - Gegenargument: „Mit n=23 ist jede Clusterzahl fragil.“ — Replik: Zugestanden; daher dient das Clustering primär der Strukturierung (Modellsparbarkeit, Übertragbarkeit), nicht als harte wissenschaftliche Typologie.

Antizipierte Verteidigungsfragen. - „Wie robust ist k=3 gegenüber dem Zählerausschluss?“ → Sollte geprüft werden (Sensitivität gegen Ein-/Ausschluss einzelner Zähler) — offener Robustheitscheck.

Literatur. Rousseeuw (1987); Lloyd (1982).

6. Form-Cluster und Magnitude-Sicht getrennt

Entscheidung. Zwei separate Analysen: (B1) Form-Cluster auf normierten Tagesprofilen, (B2) Magnitude-Sicht (Median-Tagesenergie vs. Werktag/Wochenend-Ratio) ohne Clustering (01_eda Block 5).

Begründung. - Zwei orthogonale Fragen: „Wer hat ein ähnliches Muster?“ (Form) vs. „Wer ist groß/klein und arbeitet wann?“ (Magnitude). Sie zu vermischen, lässt die Magnitude die Form dominieren. - Beide sind für die Anomalieerkennung relevant: Form steuert die Cluster-/ARIMA-Zuordnung; Magnitude ist Kontext für Schweregrad und Plausibilisierung. - Interpretierbarkeit: der Magnitude-Scatter ist ohne Cluster direkt lesbar.

Verworfenen Alternativen. - Ein gemeinsames Clustering über Form + Magnitude: Skalenmischung, schwer interpretierbar, Magnitude überlagert die Form.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Zwei Sichten verdoppeln den Erklärungsaufwand.“ — Replik: Ja, aber sie verhindern eine klassische Fehlinterpretation (Form-Ähnlichkeit ≠ Größen-Ähnlichkeit) und sind je für sich knapp.

Antizipierte Verteidigungsfragen. - „Sollte die Magnitude nicht ins Modell?“ → Sie geht über die zählerindividuelle Standardisierung (Z-Score/ARIMA pro Zähler) implizit ein; die getrennte Sicht dient der Exploration/Argumentation.

Literatur. —

C. Anomalieerkennungs-Methoden

7. Z-Score als Baseline — warum überhaupt eine Baseline?

Entscheidung. Wir implementieren zuerst eine bewusst simple Z-Score-Baseline auf dem STL-Residuum (03_baseline_zscore), bevor die Hauptmethode kommt.

Begründung. - Vergleichsmaßstab: eine komplexe Methode ist nur dann gerechtfertigt, wenn sie eine einfache, voll erklärbare schlägt — sonst Overengineering. Die Baseline definiert die Messlatte. - Erkenntnisgewinn vor Modellierung: die Baseline hat empirisch die zentralen Eigenschaften der Daten aufgedeckt (fat tails 2,84 % vs. 0,27 %; Top-10 = Feiertage; Heteroskedastizität) — das motiviert die

Hauptmethode datenbasiert statt aus dem Lehrbuch. - Wissenschaftliche Redlichkeit: „simpler zuerst“ ist methodischer Standard und entspricht dem Projekt-Skill anomalie-methodenwahl (Stufe 0).

Verworfenen Alternativen. - Direkt mit der komplexen Methode starten: kein Vergleichswert, keine Rechtfertigung des Mehraufwands.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Eine Baseline, die fast nur Feiertage findet, ist nutzlos.“ — Replik: Als Detektor begrenzt — als Diagnoseinstrument sehr wertvoll: genau dieser „Fehlschlag“ liefert die vier konkreten Anforderungen an die Hauptmethode (L1–L4 in konzept.md §8).

Antizipierte Verteidigungsfragen. - „Ist die Baseline nur Pflichtübung?“ → Nein; sie hat die Methodenwahl (SARIMAX mit Feiertags-Exogen) empirisch begründet.

Literatur. Hyndman & Athanasopoulos (2021).

8. Globaler statt rollender Z-Score

Entscheidung. Der Z-Score wird global über die volle Historie je Zähler berechnet, nicht in einem rollenden Fenster.

Begründung. - Trend ist bereits raus: STL hat den Trend entfernt; das Hauptargument für ein rollendes Fenster (Drift-Robustheit) entfällt weitgehend. - Maximale Einfachheit/Erklärbarkeit für eine Baseline; 1:1 als Lehrbuch-3-Sigma zitierbar. - Keine Fenster-Hyperparameter (Fensterlänge, min_periods), die die Baseline „unfair“ stark machen würden.

Verworfenen Alternativen. - Rollender Z-Score (z. B. 7-Tage): robuster gegen schleichende Drift, aber führt Hyperparameter ein und verschiebt die Baseline Richtung „Methode“; gehört eher in die Vergleichsmethoden.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Global ignoriert lokale Varianzänderungen (Heteroskedastizität).“ — Replik: Korrekt, und das ist als Limitation L3 dokumentiert — es ist ein bewusster Schwachpunkt der Baseline, der die kontextabhängige Varianz der Hauptmethode motiviert. Eine Baseline soll simpel sein, nicht alle Probleme lösen.

Antizipierte Verteidigungsfragen. - „Würde ein rollender Z-Score die Feiertags-Fehlalarme reduzieren?“ → Nein — Feiertage sind irregulär und kalenderbedingt, kein Drift-Problem; ein rollendes Fenster hilft dagegen nicht. Nur Kalenderwissen (SARIMAX) hilft.

Literatur. —

9. ARIMA/SARIMAX als Hauptmethode statt Isolation Forest

Entscheidung. Die Hauptmethode ist ein cluster-weises (S)ARIMA(X)-Forecasting; das standardisierte Residuum/Prädiktionsintervall ist der Anomalie-Score. Isolation Forest läuft nur als Vergleichsmethode mit.

Begründung. - Zeitliche Struktur explizit: ARIMA modelliert die Erwartung für jeden Zeitpunkt im Kontext; das Residuum ist per Konstruktion die „Untypischkeit für diesen Zeitpunkt“ (Kontext-Anomalie). Isolation Forest behandelt Punkte als unabhängige Beobachtungen im Merkmalsraum und ignoriert Saisonalität, sofern man sie nicht künstlich als Features einbaut. - Erklärbarkeit: ARIMA liefert ein Konfidenzband; „erwarteter Verlauf + Band + Ist-Wert“ ist im Dashboard unmittelbar nachvollziehbar — ein IF-Score (0–1) hat keine physikalische Bedeutung. Erklärbarkeit ist im Projekt ein nicht-funktionales Pflichtmerkmal (kritische Energieinfrastruktur). - Konfidenzintervall = native Schwelle: statistisch fundierte Schwelle statt heuristischer Quantil-Wahl. - Skalierung via Clustering gelöst: ein Modell pro Cluster statt pro Zähler (Entscheidung 15).

Verworfenen Alternativen. - Isolation Forest als Hauptmethode: stark bei vielen heterogenen Features ohne dominante Zeitstruktur — hier liegt aber eine dominante Zeitstruktur vor; daher nur als Vergleich. - Reines STL-Residuum + Schwelle (= Baseline): an L1–L4 gescheitert.

Ehrliche Gegenargumente & Replik. - Gegenargument: „ARIMA skaliert schlecht bei vielen Zählern und nimmt Stationarität an.“ — Replik: Skalierung durch Cluster-Modelle adressiert; Stationarität durch Differenzierung/Saisondifferenzierung (das „I“ bzw. saisonales „I“); Reststruktur per ACF/PACF und Residualdiagnostik prüfen. - Gegenargument: „Isolation Forest ist schneller und annahmefrei.“ — Replik: Stimmt, aber um den Preis fehlender Erklärbarkeit und Zeitkontext. Wir führen ihn als Vergleich, um genau diesen Trade-off zu zeigen, statt ihn zu behaupten. - Gegenargument: „Klassische Punkt-Residuen erkennen keine kollektiven Anomalien (mehrstündige Plateaus).“ — Replik: Berechtigt (Baseline-L4); ARIMA-Residuen über aufeinanderfolgende Schritte bzw. eine Aggregation des Scores über Fenster adressieren das — als Erweiterung benannt.

Antizipierte Verteidigungsfragen. - „Warum nicht Isolation Forest mit Zeit-Features (hour, dow, lag)?“ → Möglich und genau der Vergleichsaufbau; er bleibt aber eine statische Dichteschätzung ohne Konfidenzband — der Erklärbarkeitsnachteil bleibt. - „SARIMA vs. Prophet?“ → Prophet ist bequem, aber stärker black-box bei der Komponenten-Kalibrierung; SARIMAX mit exogenen Regressoren ist transparenter und statistisch fundierter.

Literatur. Box & Jenkins (1970); Liu et al. (2008, Isolation Forest); Hyndman & Athanasopoulos (2021).

10. SARIMAX mit Feiertags-Exogen (motiviert durch Baseline-Befund)

Entscheidung. Die Hauptmethode nutzt SARIMAX mit `is_holiday` (und ggf. Kalender-/Wetter-Regressoren) als exogener Variable.

Begründung. - Direkt datenmotiviert: die Baseline zeigte, dass alle Top-10-Anomalien Feiertage/Schließstage sind (negative Residuen), weil STL irreguläre Kalenderereignisse nicht lernt. Ein exogener Feiertagsregressor adressiert genau diese systematische Fehlerquelle. - Features liegen bereit: `is_holiday` plus alle 16 Bundesländer in `features.parquet` (02 features), umschaltbar sobald Standorte bekannt sind. - Erklärbar: der exogene Effekt ist als Koeffizient quantifizierbar („Feiertag senkt die erwartete Last um X kW“).

Verworfenen Alternativen. - Feiertage nachträglich aus den Ergebnissen filtern: heilt das Symptom, nicht das Modell; der Score bliebe an Feiertagen unbrauchbar. - Feiertage ignorieren: reproduziert den Baseline-Fehler.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Feiertage variieren je Bundesland — ohne Standort ist das exogene Signal unsicher.“ — Replik: Bundesweite Feiertage (die wirkungsstärksten Schließstage: Weihnachten, Ostermontag, Einheitstag) sind unstrittig; landesspezifische sind vorbereitet und nach Marja-Klärung aktivierbar. Heilige Drei Könige (in unseren Top-10) deutet bereits auf Süddeutschland/Bayern hin — konsistent mit dem Würzburg-Proxy. - Gegenargument: „Exogene Regressoren erhöhen die Overfitting-Gefahr.“ — Replik: `is_holiday` ist ein einzelner, fachlich begründeter Binärregressor — geringes Overfitting-Risiko, hohe Erklärkraft.

Antizipierte Verteidigungsfragen. - „Warum nicht auch Ferien/verkaufsoffene Sonntage?“ → Sinnvolle Erweiterung; zunächst der dominante Effekt (Feiertage), dann iterativ.

Literatur. Box & Jenkins (1970); Hyndman & Athanasopoulos (2021, dynamische Regression).

11. Kein LSTM(-Autoencoder)

Entscheidung. Wir setzen kein rekurrentes Deep-Learning-Modell ein.

Begründung. - Erklärbarkeit: ein LSTM-Autoencoder-Rekonstruktionsfehler ist schwer einem Betreiber zu erklären — Konflikt mit dem nicht-funktionalen Pflichtmerkmal. - Datenmenge/Aufwand-Nutzen: kein Labelsatz, hoher Tuning- und Rechenaufwand; klassische Verfahren lösen die dominante (saisonale) Struktur bereits gut. - Wissenschaftlicher Rahmen: Master-Hausarbeit mit Fokus Methodenvielfalt + Begründung, nicht maximale Detektionsrate.

Verworfenen Alternativen. - LSTM-Autoencoder: erst zu rechtfertigen, wenn Stufe 0–4 nachweislich scheitern (Skill anomalie-methodenwahl, Stufe 5).

Ehrliche Gegenargumente & Replik. - Gegenargument: „LSTMs erfassen nichtlineare, langreichweitige Muster, die ARIMA entgehen.“ — Replik: Zutreffend für komplexe multivariate Lasten; bei den stark saisonal-strukturierten Baumarktlasten ist der Mehrwert fraglich und der Erklärbarkeitsverlust real. Wir nennen es als Ausblick, nicht als Verzicht aus Bequemlichkeit.

Antizipierte Verteidigungsfragen. - „Habt ihr es getestet?“ → Bewusst nicht implementiert; die Begründung ist methodisch (Erklärbarkeit + Aufwand-Nutzen), nicht „keine Zeit“.

Literatur. Malhotra et al. (2016, LSTM-Encoder-Decoder).

12. Kein Foundation Model (Chronos, TimeRCD, TranAD)

Entscheidung. Zeitreihen-Foundation-/Transformer-Modelle werden diskutiert, aber nicht implementiert.

Begründung. - Erklärbarkeit als Ausschlusskriterium: Foundation Models sind Black Boxes; in kritischer Energieinfrastruktur muss ein Alarm nachvollziehbar und verantwortbar sein. - Betriebs-Footerprint: großes Modellgewicht/Compute steht im Widerspruch zur lokalen, ressourcenschonenden Verarbeitung (vgl. Entscheidungen 13/14). - Aufwand-Nutzen: ohne Labels und mit dominanter Saisonstruktur ist der erwartete Mehrwert gegenüber SARIMAX gering, der Erklärbarkeitsverlust hoch.

Verworfenen Alternativen. - Chronos (Ansari et al. 2024) (Zero-/Few-Shot-Forecasting), TranAD (Tuli et al. 2022) (Transformer-Anomalieerkennung), TimeRCD/THEMIS — als State-of-the-Art referenziert, nicht eingesetzt.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Chronos braucht kein Training und ist oft sehr stark — warum nicht wenigstens als Vergleich?“ — Replik: Fairer Punkt; als Vergleichsbenchmark (nicht als Produktivkomponente) wäre Chronos ein legitimer Ausbau und ist als solcher in der Diskussion benannt. Gegen den produktiven Einsatz spricht die Erklärbarkeit. - Gegenargument: „Erklärbarkeit von Transformern verbessert sich (Attention, SHAP).“ — Replik: Diese Erklärungen sind post-hoc und für Betreiber selten intuitiv; ein ARIMA-Konfidenzband ist direkt verständlich.

Antizipierte Verteidigungsfragen. - „Ist ‚Erklärbarkeit‘ nicht ein Vorwand, um Aufwand zu sparen?“ → Es ist ein dokumentiertes, im Energiekontext anerkanntes nicht-funktionales Requirement; zudem zeigen wir mit dem mehrstufigen Vorgehen, dass wir die Alternativen kennen und bewusst abwägen.

D. Handlungsempfehlungen (LLM)

13. LLM lokal via Ollama statt Cloud-API

Entscheidung. Handlungsempfehlungen werden von einem lokalen LLM via Ollama erzeugt, nicht über eine Cloud-API.

Begründung. - DSGVO/Datenschutz: Smart-Meter-Daten sind personenbeziehbar (Verbrauchsmuster lassen Rückschlüsse auf Anwesenheit/Betrieb zu); lokale Verarbeitung vermeidet jeden Cloud-Datenabfluss. - Reproduzierbarkeit & Kosten: feste lokale Modelle, keine API-Drift, keine laufenden Kosten, offline lauffähig. - Kontrollierbarkeit: Modell, Version und Prompt sind vollständig in unserer Hand.

Verworfen Alternativen. - Cloud-LLM (z. B. GPT-/Claude-API): höhere Sprachqualität, aber Datenschutz-/Compliance-Risiko und externe Abhängigkeit.

Ehrliche Gegenargumente & Replik. - Gegenargument: „Man könnte anonymisiert/aggregiert an die Cloud senden.“ — Replik: Möglich, aber Anonymisierung von Lastzeitreihen ist nichttrivial (Re-Identifikation über Muster); lokal zu bleiben ist die konservative, im Energiekontext gut begründbare Wahl. - Gegenargument: „Lokale 3B-Modelle sind sprachlich schwächer.“ — Replik: Zutreffend (siehe Entscheidung 14); durch erzwungenes Ausgabeformat (Structured Outputs) und enge Prompts ist die Aufgabe aber eng gefasst.

Antizipierte Verteidigungsfragen. - „Ist das LLM sicherheitskritisch?“ → Nein — es erklärt/empfiehlt, entscheidet nicht autonom; regelbasierte Leitplanken + strukturierter Output begrenzen das Risiko.

Literatur. McKenna et al. (2012); Asghar et al. (2017, Smart-Meter-Datenschutz).

14. LLM-Modellgröße: 3B (Llama 3.2) statt 7B

Entscheidung. Wir nutzen Llama 3.2 3B (statt eines 7B-Modells) als lokales Empfehlungs-LLM.

Begründung. - Format wird erzwungen, nicht ‚erhofft‘: Ollama Structured Outputs (JSON-Schema, constrained decoding auf Token-Ebene) garantiert das Ausgabeformat modellunabhängig — der Hauptgrund für ein größeres Modell (zuverlässige Strukturtreue) entfällt weitgehend. - Footprint/Geschwindigkeit: 3B passt in ~2–3 GB (Q4), läuft auf M-Series-MacBooks deutlich schneller und mit geringerem RAM — passend zu „lokal, ressourcenschonend“. - Enge Aufgabe: kurze, schemagebundene Empfehlungs-Karten (Schweregrad, Vermutung, Maßnahme) aus strukturiertem Kontext — kein freier Langtext, der ein großes Modell erfordern würde.

Verworfen Alternativen. - Qwen2.5 7B / Llama 3.1 8B: sprachlich/benchmarktechnisch stärker, aber für die enge, formatgebundene Aufgabe überdimensioniert und schwerer im Footprint. (Hinweis: die frühere Doku nannte 7B; konzept.md 5.3 und der Skill werden auf 3B angeglichen.)

Ehrliche Gegenargumente & Replik. - Gegenargument (ernst zu nehmen): „3B-Modelle sind in deutscher Fachsprache und im logischen Schließen spürbar schwächer; Empfehlungen könnten generisch oder fehlerhaft sein.“ — Replik: Bewusster Trade-off. Mitigation: (a) strenges JSON-Schema, (b) Kontext wird vom System geliefert (Zähler, Zeit, Abweichung, Wetter/Feiertag), das LLM formuliert nur, (c) regelbasierte Plausibilitätsprüfung der Felder, (d) bei Bedarf ist ein größeres Modell ein einzeliger Ollama-Tausch. Wir werden die Empfehlungsqualität qualitativ prüfen und den Trade-off offen berichten. - Gegenargument: „Warum nicht ein deutsch-optimiertes 7B (z. B. ein EM-German-Derivat)?“ — Replik: Legitim; für den Prototyp priorisieren wir Footprint + erzwungenes Format. Ein deutsch-spezialisiertes Modell ist ein klar benannter Ausbaupfad.

Antizipierte Verteidigungsfragen. - „Habt ihr 3B vs. 7B empirisch verglichen?“ → Im Prototyp-Stadium nicht systematisch; die Wahl ist durch die Aufgabencharakteristik (formatgebunden, kontextgespeist) begründet, und ein Vergleich ist als Evaluationsschritt vorgesehen.

Literatur. —

E. Übertragbarkeit

15. Cluster-basierte Übertragbarkeit statt pro-Zähler-Training

Entscheidung. Eine neue Liegenschaft/Branche wird über ihr mittleres Tagesprofil einem bestehenden Cluster-Centroid zugeordnet und nutzt dessen ARIMA-Modell; nur bei zu großer Distanz folgt Warnung

„neues Cluster nötig" bzw. ein Default-Modell. Kein Training pro Einzelzähler.

Begründung. - Skalierbarkeit: ein Modell pro Cluster (statt pro Zähler) ist sparsam, schneller und weniger überanpassungsanfällig bei kurzen Reihen. - Echte Übertragbarkeit ohne Retraining: adressiert Teil (a) der Forschungsfrage („ohne pro-Standort-Training übertragbar"). - Eingebaute Selbstkontrolle: die Distanz-zum-Centroid liefert ein Maß, ob die Übertragung überhaupt zulässig ist — ehrlicher als blindes Anwenden.

Verworfen Alternativen. - Pro-Zähler-Training: genauer pro Zähler, aber nicht übertragbar und teuer; widerspricht der Forschungsfrage. - Ein globales Modell für alle: ignoriert die belegte Heterogenität der Profile ($k=3$).

Ehrliche Gegenargumente & Replik. - Gegenargument: „Cluster-Centroide aus Baumärkten passen vielleicht auf keine andere Branche — dann trägt nichts." — Replik: Genau deshalb ist der Übertragbarkeitstest ergebnisoffen formuliert („Wie weit trägt die Cluster-Zuordnung?") und nicht als Behauptung. Ein Negativergebnis („Fremdbranche braucht eigenes Cluster") ist ein verwertbares Resultat. - Gegenargument: „Ein Cluster-Mittelmodell ist pro Zähler suboptimal." — Replik: Zugestanden; wir tauschen etwas zählerindividuelle Genauigkeit gegen Übertragbarkeit und Sparsamkeit — ein bewusster, benannter Trade-off.

Antizipierte Verteidigungsfragen. - „Wie wird die Distanzschwelle gesetzt?" → Datengetrieben aus der Intra-Cluster-Distanzverteilung der Trainingszähler (z. B. oberes Quantil); offen und im Übertragbarkeitstest zu kalibrieren.

Literatur. Lloyd (1982); Rousseeuw (1987).

Literaturverzeichnis (APA — vor Abgabe verifizieren)

- Ansari, A. F., Stella, L., Türkmen, C., et al. (2024). Chronos: Learning the language of time series. arXiv:2403.07815.
- Asghar, M. R., Dán, G., Miorandi, D., & Chlamtac, I. (2017). Smart meter data privacy: A survey. *IEEE Communications Surveys & Tutorials*, 19(4), 2820–2835.
- Box, G. E. P., & Jenkins, G. M. (1970). *Time series analysis: Forecasting and control*. Holden-Day.
- Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3–73.
- Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *KDD-96*, 226–231.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts.
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *ICDM 2008*, 413–422.
- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proc. 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.
- Malhotra, P., Ramakrishnan, A., Anand, G., Vig, L., Agarwal, P., & Shroff, G. (2016). LSTM-based encoder-decoder for multi-sensor anomaly detection. *ICML Anomaly Detection Workshop*.
- McKenna, E., Richardson, I., & Thomson, M. (2012). Smart meter data: Balancing consumer privacy concerns with legitimate applications. *Energy Policy*, 41, 807–814.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- Tuli, S., Casale, G., & Jennings, N. R. (2022). TranAD: Deep transformer networks for anomaly detection in multivariate time series data. *Proc. VLDB Endowment*, 15(6), 1201–1214.
- TimeRCD, THEMIS: Referenzen vor Abgabe ergänzen und verifizieren.